

Prédiction de la Gravité des Accidents de la Circulation Routière en France

Analyse exploratoire, nettoyage des données et modélisation prédictive par Machine Learning

Données : BAAC 2024 - Accidents Corporels de la Circulation (France)

Jeu de données : 54 401 accidents - 14 variables - 3 classes de gravité

Groupe : Issam ATRARI, Noé LABBÉ, Enzo NZENGUE MAYILA - Année 2025-2026
L3 SDN École du Numérique

1. Introduction

Les accidents de la circulation représentent un enjeu majeur de santé publique en France. En 2024, des dizaines de milliers de personnes ont été blessées ou tuées sur les routes françaises. Comprendre les facteurs qui déterminent la gravité d'un accident et pouvoir les prédire est essentiel pour orienter les politiques de prévention, optimiser le déploiement des secours et guider les investissements en sécurité routière.

Ce projet s'inscrit dans une démarche d'analyse de données appliquée : à partir des données BAAC 2024, nous réalisons une exploration approfondie des facteurs de risque, un nettoyage rigoureux des données, et développons trois modèles de machine learning dont nous comparons les performances sur un problème de classification multi-classe fortement déséquilibré.

1.1 Description des données

Le jeu de données est issu du Bulletin d'Analyse des Accidents Corporels (BAAC) pour l'année 2024, mis à disposition par le Ministère de l'Intérieur. Il contient 54 402 enregistrements, une ligne par usager impliqué dans un accident, décrits par 14 attributs :

Variable	Description
Num_Acc	Identifiant unique de l'accident (supprimé, corrompu à l'export Excel)
Département → Région	Localisation géographique (107 départements regroupés en 14 régions)
Agglomération	Accident en agglomération ou hors agglomération (2 modalités)
Luminosité	Plein jour, crépuscule, nuit avec/sans éclairage public (5 modalités)
Météo (conditions atmos.)	Normale, pluie légère/forte, brouillard, neige, grêle, etc. (10 modalités)
Type de collision	Frontale, arrière, latérale, sans collision, etc. (8 modalités)
Catégorie de route	Autoroute, route nationale, départementale, voie communale, etc. (8 modalités)
Régime de circulation	Sens unique, bidirectionnel, chaussées séparées (5 modalités)
Nombre de voies → Voies_num	Nombre de voies (numérique, extrait du texte par regex)
État de la surface	Normale, mouillée, verglacée, enneigée, huileuse, etc. (10 modalités)
Infrastructure	Pont, tunnel, carrefour à sens giratoire, chantier, etc. (11 modalités)

Variable	Description
Situation de l'accident	Sur chaussée, trottoir, piste cyclable, voie de bus, etc. (7 modalités)
Vitesse max autorisée → Vitesse_num	Limitation de vitesse en km/h (numérique, extrait par regex)
Gravité — cible	Blessé léger, Blessé hospitalisé, Tué (variable à prédire)

Tableau 1 — Description des variables du jeu de données BAAC 2024

1.2 Questions de recherche

Ce projet répond aux trois questions suivantes :

- Quels facteurs environnementaux, infrastructurels et comportementaux influencent le plus la gravité des accidents de la route ?
- Peut-on prédire automatiquement la gravité d'un accident à partir de ses caractéristiques observables avant et pendant l'événement ?
- Quel algorithme de machine learning offre les meilleures performances sur ce problème multi-classe fortement déséquilibré ?

2. Exploration et Analyse des Données

2.1 Distribution de la variable cible

La variable cible présente un fort déséquilibre de classes, caractéristique des jeux de données réels d'accidents. Sur 54 401 usagers enregistrés :

Classe	Effectif	Part	Remarque
Blessé léger	34 743	63,9 %	Classe largement majoritaire
Blessé hospitalisé	16 432	30,2 %	Classe intermédiaire
Tué	3 226	5,9 %	Classe critique et très minoritaire

Tableau 2 — Distribution de la variable cible (gravité) — BAAC 2024

Le ratio déséquilibre entre la classe majoritaire (Blessé léger) et la classe minoritaire (Tué) est de 10,8x. Ce déséquilibre sévère est un défi de la modélisation : un classifieur naïf prédisant systématiquement 'Blessé léger' atteindrait 63,9 % d'accuracy sans aucune valeur prédictive réelle. Toutes les décisions de modélisation tiennent compte de cette contrainte (class_weight='balanced', métriques macro). Les visualisations détaillées (histogrammes de distribution, bar charts par variable, heatmap de corrélation) sont disponibles dans les notebooks.

2.2 Analyse des variables explicatives

L'analyse exploratoire a mis en évidence plusieurs relations significatives entre les caractéristiques et la gravité des accidents :

Vitesse maximale autorisée : c'est la variable la plus fortement corrélée à la gravité. Les accidents mortels se produisent de manière disproportionnée sur les routes à grande vitesse (80-130 km/h), tandis que les blessés légers sont sur-représentés en zone urbaine (30-50 km/h). La médiane de vitesse pour les accidents mortels est de

80 km/h contre 50 km/h pour les blessés légers. Cette variable présente cependant 760 valeurs manquantes (1,4 %).

Luminosité et conditions météorologiques : contrairement à l'intuition, les accidents mortels surviennent proportionnellement plus souvent en plein jour (trafic plus important) qu'en conditions d'obscurité. En revanche, la nuit sans éclairage public est significativement associée à une plus grande gravité relative. La météo normale domine toutes les classes, confirmant que l'état atmosphérique ne suffit pas à expliquer la gravité, vitesse et comportement sont prédominants.

Catégorie de route : les routes nationales et départementales hors agglomération concentrent la majorité des accidents mortels, malgré un trafic moindre que les autoroutes. Ce paradoxe s'explique par l'absence de séparateur central et des vitesses pratiquées élevées. Les voies communales, à forte densité d'accidents, restent majoritairement des accidents légers.

Type de collision : les collisions frontales présentent le taux de mortalité le plus élevé. Les collisions par l'arrière et les accidents sans collision (sortie de route) montrent également une sévérité élevée sur voies rapides. Les visualisations par type de collision confirment que la configuration du choc est un prédicteur fort de la gravité.

2.3 Valeurs aberrantes et incohérences

L'exploration a révélé plusieurs anomalies nécessitant un traitement spécifique :

- Vitesses > 130 km/h (20 cas) : supérieures à la limite légale française maximale (autoroutes) traitées comme des erreurs de saisie et converties en valeurs manquantes.
- Doublons exacts : 24,3 % des lignes (13 221 enregistrements) sont des duplicatas. Ils correspondent à des accidents impliquant plusieurs usagers avec les mêmes caractéristiques environnementales. Conformément à la structure BAAC (1 ligne = 1 usager), ils ont été conservés.
- Valeurs 'Non renseigné' : converties en modalité 'Inconnu' pour préserver l'absence d'information comme signal potentiellement corrélé à la gravité.
- Identifiant Num_Acc corrompu : tous les identifiants affichent '2,02E+11' à la suite d'un export Excel, colonne supprimée (aucune valeur analytique exploitable).

3. Nettoyage et Préparation des Données

3.1 Traitement des valeurs manquantes

Les valeurs manquantes sont traitées via une imputation par la médiane, appliquée après la séparation train/test à l'intérieur du pipeline sklearn, pour éviter toute fuite de données. Les statistiques de la médiane sont calculées exclusivement sur le jeu d'entraînement et appliquées ensuite au jeu de test.

Variable	Valeurs manquantes	Pourcentage	Traitement
Météo (conditions atmos.)	11	0,02 %	Modalité manquante → imputation médiane
Vitesse_num	760	1,40 %	Non renseigné ou > 130 km/h → NaN, imputé ensuite
Voies_num	2 264	4,16 %	#VALEURMULTI ou Non renseigné → NaN, imputé ensuite
TOTAL	3 035	5,58 %	Imputation médiane post-split dans chaque pipeline

Tableau 3 — Inventaire des valeurs manquantes et traitements appliqués

Note sur les effectifs : le jeu de données brut contient 54 402 enregistrements (section 1.1) ; après suppression de la colonne Num_Acc corrompue et application du pipeline de nettoyage, 54 401 usagers sont retenus pour la modélisation (une ligne sans valeur cible exploitable est retirée).

3.2 Ingénierie des variables

Deux transformations clés ont été réalisées pour rendre les variables textuelles exploitables par les modèles :

- Extraction numérique de la vitesse : la variable textuelle '50 km/h' a été parsée par regex pour extraire la valeur numérique entière (Vitesse_num). Les valeurs supérieures à 130 km/h (hors barème légal) sont converties en NaN.
- Extraction du nombre de voies : la variable textuelle '2 voie(s)' a été transformée en entier (Voies_num). Les cas '#VALEURMULTI voie(s)', artéfacts du système source et 'Non renseigné' deviennent NaN.
- Agrégation géographique : les 107 départements ont été regroupés en 14 régions administratives françaises pour éviter l'explosion dimensionnelle en one-hot encoding (107 → 14 modalités) tout en préservant l'information géographique pertinente.

3.3 Stratégie d'encodage

Deux encodages distincts ont été produits, adaptés à chaque famille d'algorithmes :

Stratégie	Dimensions	Modèles	Justification
Encodage ordinal (Label Encoding)	12 colonnes	Random Forest, XGBoost	Préserve l'ordre sémantique (ex. Luminosité : jour < crépuscule < nuit sans éclairage). Adapté aux modèles arbres qui gèrent nativement les variables catégorielles ordinales.
One-Hot Encoding (OHE)	81 colonnes	Régression Logistique	Crée une variable binaire par modalité, éliminant tout ordre artificiel. Indispensable pour la régression logistique (hypothèse de linéarité).

Tableau 4 — Stratégies d'encodage et algorithmes associés

Fichiers exportés : X_lab_encoded.csv (encodage ordinal, 12 colonnes), X_oh_encoding.csv (OHE, 81 colonnes), y_gravite.csv (variable cible) et

label_encoding_mappings.json (correspondances codes/modalités pour l'interprétabilité).

4. Construction des Modèles Prédicatifs

4.1 Protocole de test

Le protocole de test est conçu pour garantir la reproductibilité et l'équité de comparaison entre les modèles. Il repose sur une séparation train/test unique : 80 % entraînement (43 520 lignes) / 20 % test (10 881 lignes), stratifiée sur la variable cible (random_state=42). Le même split est utilisé pour les trois modèles : toute différence de performance est attribuable uniquement au modèle, pas au hasard de l'échantillonnage.

Une validation croisée 5-Fold Stratifiée sur l'ensemble du jeu de données évalue la stabilité et détecte le surapprentissage. La baseline DummyClassifier stratifiée (F1 Macro = 0,334) fixe le seuil minimal à dépasser. Les métriques principales retenues sont le F1 Macro (critère principal, traite équitablement les 3 classes) et le F1 de la classe 'Tué' (critère métier prioritaire, car un faux négatif peut avoir des conséquences graves). L'imputation des valeurs manquantes est intégrée dans chaque pipeline sklearn et calculée exclusivement sur les données d'entraînement.

4.2 Régression Logistique (Multinomiale) — Issam

La régression logistique constitue le modèle de référence interprétable, configuré en mode multinomial avec régularisation L2 (C=1,0) pour prévenir le surapprentissage sur les 81 features OHE.

Paramètre	Justification
class_weight='balanced'	Pondère chaque classe inversement à sa fréquence → atténue le biais vers la classe majoritaire (×5,6 pour Tué)
solver='lbfgs'	Algorithme quasi-Newton stable et efficace pour les problèmes multi-classes de taille moyenne
max_iter=1000	Nombre d'itérations suffisant pour la convergence (observée en ~35 itérations en pratique)
C=1.0	Régularisation L2 modérée — équilibre biais/variance adapté au nombre de features (81)
multi_class='multinomial'	Optimise directement la vraisemblance multi-classes (vs. One-vs-Rest)
StandardScaler	Indispensable — les coefficients LR sont sensibles aux échelles relatives des features

Tableau 5 — Paramètres de la Régression Logistique et justifications

4.3 Random Forest — Noé

Le Random Forest est un algorithme d'ensemble bagging qui entraîne 200 arbres de décision sur des sous-échantillons et agrège leurs prédictions par vote majoritaire. Il ne nécessite pas de normalisation et gère nativement les variables ordinales.

Paramètre	Justification
n_estimators=200	200 arbres offrent un bon compromis variance/temps — au-delà, les gains marginaux sont négligeables

Paramètre	Justification
class_weight='balanced'	Pondère les échantillons à l'entraînement proportionnellement à 1/fréquence_classe
max_features='sqrt'	Sélection aléatoire de $\sqrt{12} \approx 3$ features par nœud — décorrèle les arbres et réduit la variance
n_jobs=-1	Parallélisation sur tous les cœurs disponibles — réduction du temps d'entraînement
random_state=42	Reproductibilité garantie des résultats

Tableau 6 — Paramètres du Random Forest et justifications

4.4 XGBoost (Gradient Boosting optimisé) — Enzo

XGBoost est un algorithme de boosting séquentiel qui construit des arbres de manière additive en corrigeant les erreurs du modèle précédent. La mise en œuvre inclut un pipeline d'optimisation avancée en cinq étapes :

- Étape 1 : Baseline XGBoost : entraînement initial avec hyperparamètres par défaut et `sample_weight='balanced'` pour le rééquilibrage multi-classe. F1 Macro baseline = 0,469 vs 0,332 pour le dummy.
- Étape 2 : Recherche d'hyperparamètres : `RandomizedSearchCV` (30 itérations, 5-Fold Stratifiée) sur la grille `n_estimators` ∈ {100,200,300,500}, `max_depth` ∈ {3..8}, `learning_rate` ∈ {0.01..0.3}, `subsample` ∈ {0.6..1.0}, `colsample_bytree` ∈ {0.6..1.0}. Meilleurs paramètres : `max_depth=5`, `lr=0.1`, `subsample=0.8`, `colsample=0.8`.
- Étape 3 : Early Stopping : ré-entraînement avec `n_estimators=1000` (plafond élevé) et arrêt si aucune amélioration du `mlogloss` sur 20 itérations consécutives. Nombre optimal d'arbres : 349 (vs 100 du `GridSearch` démontre la valeur de l'early stopping).
- Étape 4 : Calibration des probabilités : `Platt Scaling` (`CalibratedClassifierCV`) recalibre les probabilités vers les fréquences réelles, car les probabilités brutes avec `class_weight` sont biaisées ($P(\text{Tué}) \approx 21\%$ vs réalité 5,9 %).
- Étape 5 : Optimisation du seuil de décision : le seuil `argmax` par défaut (1/3 pour 3 classes) est sous-optimal. Optimisation du seuil de la classe 'Tué' pour maximiser son F1-score : seuil optimal = 0,15 (vs 0,33 par défaut).

Paramètre	Justification
n_estimators=349	Nombre optimal d'arbres déterminé par early stopping
max_depth=5	Profondeur maximale, compromis expressivité/surapprentissage
learning_rate=0.1	Taux d'apprentissage modéré, convergence stable
subsample=0.8	80 % des données par arbre, réduction de variance
colsample_bytree=0.8	80 % des features par arbre, décorrélacion des arbres
sample_weight='balanced'	Rééquilibrage multi-classe via pondération des exemples

Tableau 7 — Paramètres optimaux de XGBoost et justifications

5. Résultats et Comparaison des Modèles

5.1 Métriques globales

Performances obtenues sur le jeu de test (10 881 lignes, non vues pendant l'entraînement). Même split stratifié random_state=42 pour tous les modèles :

Modèle	Accuracy	F1 Macro	F1 Tué
Baseline (Dummy stratifié)	51,0 %	0,334	0,048
Régression Logistique	57,4 %	0,455	0,242
Random Forest	62,5 %	0,459	0,177
XGBoost (optimisé)	64,8 %	0,475	0,266

Tableau 8 — Comparaison des performances globales (jeu de test : 10 881 lignes, random_state=42)

5.2 Performances détaillées par classe

La décomposition par classe révèle des comportements très différents selon l'algorithme, en particulier sur la classe 'Tué' :

Modèle	Blessé léger			Blessé hospitalisé			Tué		
	Préc.	Rappel	F1	Préc.	Rappel	F1	Préc.	Rappel	F1
Rég. Logistique	0,825	0,687	0,750	0,430	0,327	0,371	0,151	0,609	0,242
Random Forest	0,761	0,757	0,759	0,459	0,427	0,442	0,151	0,212	0,177
XGBoost	0,764	0,847	0,803	0,523	0,270	0,357	0,191	0,439	0,266

Tableau 9 — Précision, Rappel et F1 par classe et par modèle (jeu de test)

5.3 Validation croisée et stabilité

La validation croisée 5-Fold stratifiée appliquée à la Régression Logistique confirme la robustesse du modèle de référence :

Modèle	F1 Macro ($\mu \pm \sigma$)	Balanced Acc. ($\mu \pm \sigma$)	Accuracy ($\mu \pm \sigma$)
Régression Logistique	0,451 $\pm$ 0,002	0,536 $\pm$ 0,004	0,572 $\pm$ 0,002
Random Forest	0,459 $\pm$ 0,005	0,465 $\pm$ 0,004	0,629 $\pm$ 0,003

Tableau 10 — Validation croisée 5-Fold Stratifiée (μ = moyenne, σ = écart-type sur 5 folds)

Les écarts-types très faibles ($\sigma \leq 0,004$) témoignent d'une grande stabilité du modèle, et l'écart entre apprentissage et test reste négligeable, signe d'une généralisation satisfaisante sans surapprentissage. Faute de temps, cette validation croisée n'a été conduite que pour la Régression Logistique ; les performances des autres modèles sont reportées sur le jeu de test commun (Tableaux 8 et 9).

5.4 Importance des variables

Les trois modèles s'accordent sur les variables les plus prédictives de la gravité des accidents :

- Vitesse_num : quatrième variable pour XGBoost (Gain) et troisième pour Random Forest. Relation monotone : plus la vitesse est élevée, plus la probabilité de décès augmente.
- Type de collision : troisième variable pour XGBoost (Gain) et 2^{ème} variable pour Random Forest. La collision frontale est la configuration la plus meurtrière.

- Région : première variable pour Random Forest et deuxième variable pour XGBoost, disparités géographiques marquées entre régions rurales et urbaines.
- Agglomération : première variable pour XGBoost
- Luminosité et état de la surface : importance secondaire mais significative, conditions nocturnes et surfaces dégradées amplifient la gravité des accidents à haute vitesse.

L'analyse SHAP (SHapley Additive exPlanations) réalisée sur XGBoost permet d'expliquer individuellement chaque prédiction : la contribution marginale de chaque feature à la prédiction d'un accident spécifique est quantifiée, offrant une interprétabilité locale utilisable par les décideurs publics.

6. Conclusion

6.1 Synthèse des résultats

Ce projet a permis d'explorer, nettoyer et modéliser 54 401 usagers impliqués dans des accidents de la circulation routière en France (BAAC 2024) pour prédire automatiquement la gravité. Trois algorithmes ont été développés et comparés rigoureusement sur le même protocole de test :

- Régression Logistique (Accuracy 57,4 %, F1 Macro 0,455) : modèle rapide et interprétable. Meilleur rappel sur les accidents mortels (60,9 %). Moins précis, il génère davantage de fausses alarmes (précision Tué : 15,1 %).
- Random Forest (Accuracy 62,5 %, F1 Macro 0,459) : meilleure stabilité sur les blessés légers et hospitalisés. Meilleur F1 sur la classe 'Blessé hospitalisé' (F1=0,442 vs 0,357 pour XGBoost). Moins performant sur la classe 'Tué' (F1=0,177).
- XGBoost (Accuracy 64,8 %, F1 Macro 0,475) : meilleur modèle global en accuracy, F1 macro et sur la classe 'Tué' (F1 = 0,266). Meilleur compromis précision/rappel sur la classe critique. Notons que le Random Forest reste supérieur sur la classe 'Blessé hospitalisé' (F1 = 0,442 vs 0,357).

6.2 Recommandation

XGBoost est recommandé comme modèle de déploiement : il offre les meilleures performances globales (F1 Macro, Accuracy), le meilleur F1 sur la classe 'Tué' avec un compromis précision/rappel supérieur, et bénéficie de l'interprétabilité SHAP pour justifier chaque prédiction auprès des décideurs.

Note sur le choix précision/rappel : en contexte de sécurité routière, si minimiser les cas mortels non détectés (faux négatifs) est prioritaire, la Régression Logistique offre un rappel de 60,9 % (vs 43,9 % pour XGBoost), mais au prix d'une précision très faible (15,1 %), donc beaucoup de fausses alarmes potentiellement coûteuses. XGBoost offre le meilleur équilibre global (F1 Tué = 0,266).

6.3 Limites et perspectives

- Déséquilibre sévère (5,9 % de décès) : aucun modèle ne prédit bien la classe 'Tué'. Techniques à explorer : SMOTE, Focal Loss, ensembles asymétriques.

- Structure BAAC : 1 ligne = 1 usager, pas 1 accident unique. Les accidents multi-victimes créent des corrélations intra-groupe non capturées par la validation croisée standard.
- Données manquantes sur des variables très prédictives (Vitesse_num : 1,4 %, Voies_num : 4,2 %).
- Absence de données comportementales : alcoolémie, port de la ceinture, usage du téléphone, facteurs majeurs absents du BAAC standard.
- Perspectives : stacking d'ensemble (LR + RF + XGB), intégration de données météo temps-réel, modèles de survie pour les prédictions temporelles.

6.4 Reproductibilité

Tous les résultats présentés sont intégralement reproductibles à partir du même jeu de données (accidents_2024.csv), en exécutant les notebooks dans l'ordre suivant :

- nettoyage_des_donnees.ipynb : Génère X_lab_encoded.csv, X_oh_encoding.csv, y_gravite.csv, label_encoding_mappings.json
- logistic_regression.ipynb : Analyse et évaluation de la Régression Logistique
- random_forest.ipynb : Analyse et évaluation du Random Forest
- analyse_xgboost.ipynb : Analyse avancée de XGBoost (tuning, calibration, SHAP, optimisation du seuil)
- comparaison_modeles.ipynb : Comparaison unifiée des trois modèles (random_state=42 partout, même split)

Environnement : Python 3.x, scikit-learn, xgboost, pandas, numpy, matplotlib, seaborn, shap.